

Wstęp do Przetwarzania Języka Naturalnego (NLP) - Wykład 1

1. Podstawowe pojęcia

- " **NLP (Natural Language Processing)** to dziedzina sztucznej inteligencji, która zajmuje się interakcją między komputerami a językami ludzkimi. Jej głównym celem jest sprawienie, by komputery rozumiały, interpretowały i generowały ludzki język w sposób wartościowy.
- " **Tokenizacja** to absolutnie pierwszy krok w przetwarzaniu tekstu. Polega na podzieleniu długiego ciągu znaków (np. całego zdania) na mniejsze fragmenty zwane tokenami. Tokenem może być całe słowo, część słowa lub nawet pojedynczy znak interpunkcyjny.

2. Przełomowe Architektury

- " Do 2017 roku w NLP dominowały sieci rekurencyjne (RNN). Były one jednak powolne, ponieważ musiały czytać tekst słowo po słowie, od lewej do prawej.
- " W 2017 roku badacze z Google opublikowali słynny artykuł zatytułowany *"Attention Is All You Need"*, w którym zaprezentowali architekturę **Transformer**.
- " Transformer zrewolucjonizował NLP, ponieważ pozwala na analizowanie wszystkich słów w zdaniu jednocześnie (zrównoleglenie obliczeń) dzięki tzw. mechanizmowi uwagi (attention mechanism).

3. Współczesne wyzwania LLM (Large Language Models)

- " **Halucynacje:** To zjawisko, w którym model językowy (np. ChatGPT lub Bielek) generuje odpowiedzi, które brzmią niezwykle przekonująco i logicznie, ale są w rzeczywistości całkowicie fałszywe lub zmyślane.
- " **Rozwiązanie - RAG:** Aby walczyć z halucynacjami, inżynierowie stosują architekturę RAG (Retrieval-Augmented Generation). Polega ona na tym, że zanim model wygeneruje odpowiedź, system najpierw przeszukuje zewnętrzną, wiarygodną bazę dokumentów (np. notatki studenta) i dostarcza je modelowi jako tło do stworzenia odpowiedzi.